

Сравнительный анализ KAN и MLP в архитектуре TabKANet для табличных данных

Стеблій Мария

29.06.2026

1 Постановка задачи

1.1 Цель исследования

Цель данной работы — сравнение эффективности двух типов нейронных сетей: **Kolmogorov-Arnold Networks (KAN)** и традиционных **Multilayer Perceptrons (MLP)** в контексте обработки табличных данных. В качестве базовой архитектуры используется **TabKANet** — гибридная модель, объединяющая преимущества KAN и Transformer.

1.2 Мотивация

Табличные данные остаются доминирующим форматом в реальных бизнес-приложениях: финансы, медицина, электронная коммерция. Несмотря на успехи Transformer в NLP и CV, их применение к табличным данным долгое время уступало градиентному бустингу (XGBoost, CatBoost).

Основные проблемы нейросетевых подходов к табличным данным:

1. **Чувствительность к масштабу и распределению** числовых признаков
2. **Отсутствие интерпретируемости** — "черный ящик"
3. **Сложность учета нелинейных взаимодействий** между признаками

1.3 Почему KAN?

Kolmogorov-Arnold Networks предлагают принципиально иной подход:

- Вместо фиксированных активаций на нейронах — **обучаемые функции на ребрах**
- Естественная интерпретируемость через визуализацию сплайнов
- Теоретическое обоснование: аппроксимация любых непрерывных функций

2 Математические основы KAN

Теорема 1 (Теорема Колмогорова–Арнольда) *Любая непрерывная функция многих переменных может быть представлена в виде суперпозиции непрерывных функций одной переменной:*

$$f(x_1, \dots, x_n) = \sum_{q=1}^{2n+1} \Phi_q \left(\sum_{p=1}^n \phi_{q,p}(x_p) \right) \quad (1)$$

где $\phi_{q,p}$ и Φ_q — непрерывные функции одной переменной.

2.1 KAN как нейросетевая реализация

В отличие от MLP, где на узлах применяются фиксированные активации, в KAN обучаемые функции находятся на ребрах. Глубокий KAN представляет собой композицию L слоев:

$$\text{KAN}(x) = (\Phi_{L-1} \circ \Phi_{L-2} \circ \dots \circ \Phi_0)(x) \quad (2)$$

Каждый слой Φ_l отображает n_l -мерный вход в n_{l+1} -мерный выход:

$$\Phi_l(x) = \begin{pmatrix} \sum_{p=1}^{n_l} \phi_{l,1,p}(x_p) \\ \sum_{p=1}^{n_l} \phi_{l,2,p}(x_p) \\ \vdots \\ \sum_{p=1}^{n_l} \phi_{l,n_{l+1},p}(x_p) \end{pmatrix} \quad (3)$$

Каждая функция $\phi_{l,q,p}$ является обучаемой и представляет собой линейную комбинацию фиксированной базовой функции и В-сплайна:

$$\phi_{l,q,p}(x) = w_{l,q,p}^{(b)} \cdot \text{SiLU}(x) + w_{l,q,p}^{(s)} \cdot \text{spline}(x) \quad (4)$$

где $\text{SiLU}(x) = x \cdot \sigma(x)$ — фиксированная гладкая функция, а $\text{spline}(x)$ — В-сплайн, определяемый как линейная комбинация базисных функций:

$$\text{spline}(x) = \sum_i c_{l,q,p,i} B_{i,k}(x) \quad (5)$$

Базисные функции $B_{i,k}(x)$ удовлетворяют рекуррентному соотношению Кокса–де Бура:

$$B_{i,0}(x) = \begin{cases} 1, & t_i \leq x < t_{i+1} \\ 0, & \text{иначе} \end{cases} \quad (6)$$

$$B_{i,k}(x) = \frac{x - t_i}{t_{i+k} - t_i} B_{i,k-1}(x) + \frac{t_{i+k+1} - x}{t_{i+k+1} - t_{i+1}} B_{i+1,k-1}(x) \quad (7)$$

Таким образом, KAN обладает гораздо большей выразительностью, чем MLP, за счет:

- Многослойной композиции обучаемых функций
- Индивидуальных функций для каждой пары "вход-выход"
- Возможности визуализации каждого преобразования

2.2 Преимущества KAN перед MLP

Характеристика	MLP	KAN
Активации на узлах	Фиксированные (ReLU, SiLU)	Отсутствуют
Обучаемые функции	На ребрах (веса)	На ребрах (сплайны)
Интерпретируемость	Низкая	Высокая (визуализация сплайнов)
Аппроксимация	Универсальная	Универсальная
Количество параметров	Меньше	Больше (B-сплайны)

Таблица 1: Сравнение KAN и MLP

3 Архитектура TabKANet

3.1 Исходная архитектура TabKANet

Авторская архитектура TabKANet включает следующие компоненты:

1. **Кодирование категориальных признаков:** ColumnEmbedding
2. **Кодирование непрерывных признаков:** KAN $\rightarrow$ BatchNorm $\rightarrow$ Reshape
3. **Трансформер:** Self-Attention + MLP (FFN)
4. **Классификатор:** MLP




Рис. 1: Архитектура TabKANet (из оригинальной статьи)




Рис. 2: Иллюстрация процедуры потока данных в TabKANet (из оригинальной статьи)

3.2 Модификация: KAN-Transformer

В рамках данной работы предложена модификация — замена стандартного Transformer на **KAN-Transformer**, где Feed-Forward Network (FFN) заменена на KAN:

$$\text{FFN}_{\text{KAN}}(x) = \text{KAN}(x) = (\Phi_{L-1} \circ \Phi_{L-2} \circ \dots \circ \Phi_0)(x) \quad (8)$$

Стандартный FFN:

$$\text{FFN}_{\text{MLP}}(x) = W_2 \cdot \sigma(W_1 \cdot x + b_1) + b_2 \quad (9)$$

Почему это важно:

- KAN позволяет визуализировать внутренние преобразования FFN
- Стандартный MLP-трансформер — черный ящик
- KAN-трансформер — интерпретируемая "белая коробка"

3.3 Полная архитектура модифицированного TabKANet

$$\begin{aligned}
 \text{Embed}_{\text{cat}} &= \text{ColumnEmbedding}(X_{\text{cat}}) \\
 \text{Embed}_{\text{cont}} &= \text{BatchNorm}(\text{KAN}(X_{\text{cont}})) \\
 X &= [\text{Embed}_{\text{cat}}; \text{Embed}_{\text{cont}}] \\
 \text{For } l &= 1 \text{ to } L : \\
 X &= X + \text{Attention}(X) \\
 X &= X + \text{KAN}(X) \quad (\text{вместо MLP FFN}) \\
 \text{Output} &= \text{MLP}(X)
 \end{aligned} \quad (10)$$

3.4 Преимущества предложенной модификации

1. **Интерпретируемость FFN** — визуализация сплайнов каждого слоя
2. **Сохранение гладкости** — B-сплайны обеспечивают гладкие преобразования
3. **Адаптивность** — сетка сплайнов адаптируется к распределению данных




Рис. 3: KAN Encoder: преобразование каждого непрерывного признака (ForestCovertype). По оси X — нормализованное значение признака, по оси Y — вклад в эмбединг.

4 Визуализация интерпретируемых компонентов KAN

Одним из главных преимуществ KAN перед MLP является возможность визуализации внутренних преобразований. Ниже представлены визуализации, полученные из обученной модели KAN-Transformer на датасете ForestCovertype **до и после применения прунинга 20%**.

4.1 KAN Encoder: влияние непрерывных признаков

На рисунке 3 показаны сплайны KAN-энкодера, преобразующие сырые непрерывные признаки в эмбединги перед подачей в Transformer. Поскольку прунинг не применялся к KAN Encoder, представлена только одна визуализация.

Анализ:


- Признаки демонстрируют разнообразные формы зависимостей: линейные, S-образные, с пороговыми эффектами
- Некоторые признаки имеют слабое влияние (кривая около нуля)
- Это показывает, как KAN адаптируется к различным типам числовых признаков

4.2 KAN-Transformer FFN: внутренние преобразования по слоям


На рисунках 4 показаны сплайны FFN для всех трех слоев KAN-Transformer до и после прунинга. Каждый ряд соответствует одному слою, каждый столбец — состоянию модели (до и после прунинга). Именно здесь видно влияние прунинга, применённого к FFN слоям.

Ключевые наблюдения:


1. После прунинга количество активных нейронов уменьшилось на каждом слое (видны более "пустые" графики)
2. Оставшиеся сплайны стали проще, но сохранили основные формы
3. **Слой 1:** сложные формы
4. **Слой 2:** более разглаженные экспоненты, синусоиды
5. **Слой 3:** ещё больше простых экспонент
6. Прунинг удаляет избыточные нейроны, не нарушая основные информативные паттерны



(a) Слой 1: слева — до прунинга, справа — после прунинга



(b) Слой 2: слева — до прунинга, справа — после прунинга



(c) Слой 3: слева — до прунинга, справа — после прунинга

Рис. 4: Сравнение FFN сплайнов KAN-Transformer по слоям до и после прунинга (20%) на датасете ForestCovertype.

5 Эксперименты и результаты

5.1 Датасеты

В работе использованы 6 датасетов различных типов:

Датасет	Тип	Признаки	Размер	Метрика
BankMarketing	Бинарная классификация	17	45 211	AUC
OnlineShoppers	Бинарная классификация	18	12 330	AUC
ImageSegmentation	Мультикласс (7)	20	2 310	Macro F1
ForestCoverture	Мультикласс (7)	55	581 012	Macro F1
CA House	Регрессия	10	20 640	RMSE
CPU Small	Регрессия	13	8 192	RMSE

Таблица 2: Характеристики использованных датасетов

5.2 Результаты экспериментов

5.2.1 Банковский маркетинг (BankMarketing)

Модель	Mean	Std	Δ от baseline
KAN-Transformer (10 эпох)	0.9331	0.0011	—
KAN-Transformer (после прунинга)	0.9334	0.0010	+0.0003
KAN-Transformer (fine-tuned)	0.9345	0.0010	+0.0014
Standard Transformer (10 эпох)	0.9307	0.0022	—
Standard Transformer (fine-tuned)	0.9327	0.0020	+0.0020

Таблица 3: Результаты на BankMarketing (AUC)

Вывод: KAN-Transformer демонстрирует более высокую стабильность (меньший std) и лучшую итоговую метрику.

5.2.2 Мультиклассовая классификация

Модель	Mean	Std	Δ от baseline
KAN-Transformer (10 эпох)	0.9356	0.0137	—
KAN-Transformer (fine-tuned)	0.9476	0.0172	+0.0120
Standard Transformer (10 эпох)	0.9550	0.0069	—
Standard Transformer (fine-tuned)	0.9623	0.0061	+0.0073

Таблица 4: Результаты на ImageSegmentation (Macro F1)

Модель	Mean	Std	Δ от baseline
KAN-Transformer (10 эпох)	0.6537	0.0086	—
KAN-Transformer (fine-tuned)	0.6915	0.0054	+0.0378
Standard Transformer (10 эпох)	0.6480	0.0067	—
Standard Transformer (fine-tuned)	0.6776	0.0046	+0.0296

Таблица 5: Результаты на ForestCovertypes (Macro F1)

Вывод: На большом датасете ForestCovertypes KAN-Transformer показывает значительно лучшую способность к дообучению после прунинга (+3.78% против +2.96%).

5.2.3 Регрессия

Модель	Mean	Std	Δ от baseline
KAN-Transformer (10 эпох)	7.249	0.384	—
KAN-Transformer (fine-tuned)	6.699	0.383	-0.550
Standard Transformer (10 эпох)	7.273	0.078	—
Standard Transformer (fine-tuned)	6.713	0.102	-0.560

Таблица 6: Результаты на CA House (RMSE, меньше — лучше)

Модель	Mean	Std	Δ от baseline
KAN-Transformer (10 эпох)	70.17	1.124	—
KAN-Transformer (fine-tuned)	69.26	1.159	-0.91
Standard Transformer (10 эпох)	69.75	1.219	—
Standard Transformer (fine-tuned)	68.85	1.288	-0.90

Таблица 7: Результаты на CPU Small (RMSE, меньше — лучше)

5.3 Анализ эффективности прунинга

Важным экспериментом стало исследование устойчивости моделей к прунингу 20% нейронов:

Датасет	KAN: падение после прунинга	KAN: восст.	Std: восст.
BankMarketing	-0.0003	+0.0014	+0.0020
OnlineShoppers	-0.0000	+0.0009	+0.0005
ImageSegmentation	-0.0012	+0.0121	+0.0073
ForestCovertypes	-0.0091	+0.0378	+0.0296
Cahouse	0.0188	-0.5499	-0.5601
CPU Small	0.0034	-0.9154	-0.8937

Таблица 8: Изменение метрик после прунинга и дообучения

Ключевое наблюдение: KAN демонстрирует лучшее восстановление после прунинга на сложных датасетах (ForestCovertypes).

6 Выводы

6.1 Основные результаты

1. **KAN-Transformer не уступает стандартному Transformer** по качеству, а на некоторых датасетах превосходит его.
2. **Прунинг 20% нейронов практически не влияет на качество** (падение менее 0.01 по AUC/F1 для большинства датасетов).
3. **KAN демонстрирует лучшее восстановление после прунинга** на сложных мультиклассовых задачах (+3.78% против +2.96%).
4. **KAN обеспечивает интерпретируемость**, недоступную для MLP: визуализация сплайнов позволяет понять, как каждый признак влияет на результат.
5. **Визуализация FFN до и после прунинга** показала, что основные паттерны сохраняются, а удаляются только избыточные нейроны.

6.2 Преимущества предложенной модификации

- **KAN-трансформер** — белая коробка в отличие от черного ящика MLP
- Визуализация FFN-преобразований — то, что стандартный Transformer скрывает
- Сохранение производительности при значительном сокращении параметров

Список литературы

- [1] Weihao Gao, Zheng Gong, Zhuo Deng, Fujun Rong, Chucheng Chen, Lan Ma. TabKANet: Tabular Data Modeling with Kolmogorov-Arnold Network and Transformer. *arXiv preprint arXiv:2409.08806*, 2024. <https://arxiv.org/abs/2409.08806>.
- [2] Z. Liu, Y. Wang, S. Vaidya, F. Ruehle, J. Halverson, M. Soljačić, T. Y. Hou, M. Tegmark. KAN: Kolmogorov-Arnold Networks. *arXiv preprint arXiv:2404.19756*, 2024.
- [3] Ashish Vaswani, Noam Shazeer, Niki Parmar, et al. Attention Is All You Need. *Advances in Neural Information Processing Systems*, 2017.